

# Assessment of Convolutional Neural Networks for Automated Classification of Chest Radiographs

**Propósito:** Avaliar a capacidade das redes neurais convolucionais (CNNs) em problemas de classificação binária de alto desempenho, utilizando radiografias de tórax para detecção de anormalidades.

**Resumo:** Redes neurais convolucionais treinadas usando 20.000 radiografias de tórax rotuladas mostram-se promissoras para a classificação automatizada de radiografias de tórax como normais ou anormais, permitindo a triagem de pacientes na prática clínica.

**Base de Dados:** foram adquiridas 313.719 radiografias de tórax frontal obtidas entre 1998 e 2012, junto com relatórios de texto associados e um rótulo prospectivo do radiologista responsável. Após a etapa de pré-processamento, se mantiveram 216.431 radiografias de tórax, sendo que 55% eram de pacientes masculinos e 79% eram rotuladas como anormais. Por fim, foram usadas 180.000 imagens para treinamento, 20.000 para validação e 533 imagens para teste, sendo esse último submetido a um aval de rotulagem por 3 radiologistas.

**Conclusão:** As Redes Neurais Convolucionais, treinadas com um tamanho modesto de radiografias de tórax rotuladas, alcançaram um alto desempenho de diagnóstico na classificação de radiografias de tórax como normais ou anormais. Desse modo, tem-se que essa pode ser uma ferramenta útil na priorização de pacientes com radiografias caracterizadas como anormais.

- Uma ferramenta importante que pode **reduzir atrasos** em atendimentos de grandes e pequenas organizações de saúde (o acúmulo de grandes quantidades de radiografias trouxe aos especialistas mais variáveis e padrões a serem considerados no diagnóstico de um paciente).
- Dificuldade em encontrar grandes quantidades de dados confiáveis, pois **dados ruidosos** podem inviabilizar a confiança na previsão dos modelos treinados.
- **Combinar o julgamento do médico com algoritmos de aprendizagem profunda**, como CNNs, melhora o desempenho na interpretação da radiografia e triagem do paciente.
- Foi treinado vários modelos da CNN usando arquiteturas que são bem conhecidas na literatura, como **AlexNet**, **ResNet**, e **DenseNet**.
- Para permitir uma análise acessível dos resultados do modelo CNN, foi realizado o **mapeamento de ativação de classe (CAMs)** que mostram as áreas de uma determinada imagem que são mais responsáveis por sua classificação.
- **Conjuntos de dados moderados** (com 20.000 imagens, por exemplo) demonstraram ter um bom desempenho, não sendo muito discrepante a análise de um conjunto moderado em relação a um mais complexo (com 200.000 imagens, por exemplo).

# Métricas de Avaliação

- **Matriz de Confusão:** erros e acertos do modelo, comparados com o resultado esperado.

|      |     | Detectada                |                          |
|------|-----|--------------------------|--------------------------|
|      |     | Sim                      | Não                      |
| Real | Sim | Verdadeiro Positivo (VP) | Falso Negativo (FN)      |
|      | Não | Falso Positivo (FP)      | Verdadeiro Negativo (VN) |

- **Acurácia:** indica uma performance geral do modelo. Dentre todas as classificações, quantas o modelo classificou corretamente (boa indicação geral da performance do modelo).
- **Precisão:** dentre todas as classificações de classe Positivo que o modelo fez, quantas estão corretas (falsos positivos são considerados mais prejudiciais que falsos negativos).
- **Recall/Revogação/Sensibilidade:** dentre todas as situações de classe Positivo como valor esperado, quantas estão corretas (falsos negativos são mais prejudiciais que falsos positivos).
- **F1-Score:** média harmônica entre precisão e recall (maneira de observar a métrica de precisão e recall, se ela for baixa indica que algumas das duas métricas estão baixas) .

